

Création et automatisation d'une architecture de données

Pipeline de données sportives • traitement temps réel • qualité • Power BI

POSTGRESQL

DEBEZIUM

REDPANDA

PYSPARK

DELTA

Fatou THIAM

Parcours Data Engineer — OpenClassrooms • Projet 12 • 2026

**SPORT
DATA
SOLUTION**

1. Contexte et besoin métier

Un POC pour mesurer l'activité physique et calculer l'impact des avantages sportifs.

Objectifs du POC

Tester la faisabilité technique
Déterminer les données à collecter
Calculer l'impact financier

Prime sportive

5 % du salaire annuel brut pour les salariés
dont le trajet domicile–travail sportif est validé
selon les critères définis.

Journées bien-être

5 journées pour les salariés ayant réalisé au
moins 15 activités physiques au cours des 12
derniers mois.

Le besoin central

Construire une architecture fiable, automatisée et observable, capable de transformer des données RH et sportives en avantages salariés mesurables.

Les paramètres métier sont conçus pour pouvoir évoluer.

2. Données sources et audit


Point de départ : fiabiliser les données RH avant d’automatiser les traitements.



Résultat : une base propre pour alimenter les étapes Google Maps, simulation Strava et pipeline.

3. Architecture globale de la solution

Une architecture événementielle : Redpanda distribue les nouvelles activités vers la notification temps réel et le traitement analytique.



4. Validation des trajets domicile–travail

Contrôler automatiquement les déclarations sportives avec Google Maps.

Marche / Running

Mode Google : WALK
Distance maximale : 15 km

Vélo / Trottinette / Autres

Mode Google : BICYCLE
Distance maximale : 25 km

Principe

Adresse domicile → API Google Maps → distance →
comparaison au seuil → résultat stocké dans
commute_validation.

68

salariés contrôlés

68

trajets valides


0

anomalie détectée

Une déclaration incohérente peut ainsi être remontée automatiquement.

5. Simulation des données sportives type Strava

Créer un historique réaliste avant une future connexion directe à Strava.



2 535

activités générées

12 mois

d'historique

7 champs

métadonnées principales

PostgreSQL


stockage principal

ID • ID salarié • date de début • type • distance • date de fin • commentaire

La distance reste vide lorsque l'activité ne s'y prête pas (ex. escalade).

6. Pipeline temps réel : CDC → streaming → Delta

Détecter une nouvelle activité sans relancer manuellement toute la chaîne.



Démo live

Injection d'une activité dans PostgreSQL puis observation de sa propagation dans le flux.

Qualité

Une distance négative est isolée comme donnée invalide avant la couche métier.

Résultat

Les activités valides alimentent Delta et les traitements aval.

7. Calcul des avantages salariés

Transformer les données sportives en règles métier lisibles et auditables.

PRIME SPORTIVE

Trajet sportif validé



5 % du salaire annuel brut

Montant potentiel distingué du montant réellement attribué.

JOURNÉES BIEN-ÊTRE

**5 journées pour les salariés ayant réalisé
au moins 15 activités physiques au cours
des 12 derniers mois.**




5 jours bien-être

Le calcul utilise une fenêtre dynamique de 12 mois.

8. Monitoring et qualité des données

Valider en continu l'intégration, la volumétrie et la cohérence du pipeline.



7 contrôles historisés

- 0 Doublons activity_id
- 0 activity_id NULL
- 0 employee_id NULL
- 0 Dates incohérentes
- 0 Distances négatives
- 0 Doublons benefits
- 0 employee_id NULL benefits

Historique → [monitoring.data_quality_metrics](#)

9. Restitution Power BI: indicateurs métier

Rendre les résultats exploitables par les décideurs.

Coût des avantages

Montants potentiels et attribués de la prime sportive pour mesurer l'impact financier.

Journées bien-être

Éligibilité et nombre de jours attribués selon les activités réalisées au cours des 12 derniers mois.


Pratiques sportives

Répartition des activités et lecture par salarié / Business Unit.

Power BI devient la couche de restitution : il ne recalcule pas les règles métier, il visualise les résultats préparés par le pipeline.

Fichier livré : Sport_data.pbix

10. Tableau de bord Power BI



11. Notifications Slack et démonstration live

Prouver que le flux réagit à une nouvelle activité.

Exemple de notification

🏃 Bravo ! Une nouvelle activité sportive vient d'être détectée.

Distance et durée sont formatées pour produire un message lisible dans Slack.

Le commentaire peut également enrichir le message.



12. Bilan, limites et évolutions

Un POC fonctionnel qui valide la faisabilité technique et prépare une industrialisation.

Ce qui est validé

- Architecture automatisée
- CDC et streaming opérationnels
- Règles métier calculées
- Monitoring historisé
- Restitution Power BI

Limites du POC

- Données Strava simulées
- Exécution locale Docker
- Règles encore paramétrées dans le code
- POC non dimensionné production

Évolutions

- Connexion directe Strava
- Paramétrage externalisé
- Orchestration / alerting renforcés
- Déploiement cloud et sécurité renforcée

Résultat : un pipeline cohérent, observable et démontrable, aligné avec les besoins du POC Avantages Sportifs.

Merci — Questions / Démonstration