

# Création et automatisation d'une architecture de données

Pipeline de données sportives • traitement temps réel • qualité • Power BI

POSTGRESQL

DEBEZIUM

REDPANDA

PYSPARK

DELTA

**Fatou THIAM**

Parcours Data Engineer — OpenClassrooms • Projet 12 • 2026

**SPORT  
DATA  
SOLUTION**

# 1. Contexte et besoin métier

Un POC pour mesurer l'activité physique et calculer l'impact des avantages sportifs.

## Objectifs du POC

Tester la faisabilité technique  
Déterminer les données à collecter  
Calculer l'impact financier

## Prime sportive

5 % du salaire annuel brut pour les salariés  
dont le trajet domicile–travail sportif est validé  
selon les critères définis.

## Journées bien-être

5 journées pour les salariés ayant réalisé au  
moins 15 activités physiques au cours des 12  
derniers mois.

## Le besoin central

**Construire une architecture fiable, automatisée et observable, capable de transformer des données RH et sportives en avantages salariés mesurables.**

*Les paramètres métier sont conçus pour pouvoir évoluer.*

## 2. Données sources et audit


Point de départ : fiabiliser les données RH avant d’automatiser les traitements.



Résultat : une base propre pour alimenter les étapes Google Maps, simulation Strava et pipeline.

# 3. Architecture globale de la solution

Une architecture événementielle automatisée : une nouvelle activité déclenche les traitements temps réel et analytiques.



## 4. Validation des trajets domicile–travail

Contrôler automatiquement les déclarations sportives avec Google Maps.

### Marche / Running

Mode Google : WALK  
Distance maximale : 15 km

### Vélo / Trottinette / Autres

Mode Google : BICYCLE  
Distance maximale : 25 km

### Principe

Adresse domicile → API Google Maps → distance →  
comparaison au seuil → résultat stocké dans  
commute\_validation.

68

salariés contrôlés

68

trajets valides


0

anomalie détectée

**Une déclaration incohérente peut ainsi être remontée automatiquement.**

# 5. Simulation des données sportives type Strava

Créer un historique réaliste avant une future connexion directe à Strava.



ID • ID salarié • date de début • type • distance • date de fin • commentaire

*La distance reste vide lorsque l'activité ne s'y prête pas (ex. escalade).*

## 6. Pipeline automatisé : CDC → streaming → Delta

Détecter et traiter une nouvelle activité sans relancer manuellement la chaîne.



**DÉMO LIVE**  
1 INSERT PostgreSQL → propagation automatique jusqu'à Delta Lake

**Aucun script Spark n'est lancé manuellement après l'arrivée de l'activité.**

## 7. Calcul des avantages salariés

Transformer les données sportives en règles métier lisibles et auditables.

### PRIME SPORTIVE

Trajet sportif validé



**5 % du salaire annuel brut**

Montant potentiel distingué du montant réellement attribué.

### JOURNÉES BIEN-ÊTRE

**5 journées pour les salariés ayant réalisé  
au moins 15 activités physiques au cours  
des 12 derniers mois.**



**5 jours bien-être**

Le calcul utilise une fenêtre dynamique de 12 mois.

## 8. Monitoring, qualité et résilience

Contrôler la cohérence du pipeline et assurer la reprise automatique après incident.

**2 550**

PostgreSQL

**2 550**

Delta activities

**0**

Écart de volume

**161**

employee\_benefits

**OK**

État global

### CONTRÔLES QUALITÉ

- ✓ Doublons
- ✓ Valeurs NULL
- ✓ Dates incohérentes
- ✓ Distances négatives
- ✓ Cohérence employee\_benefits

### RÉSILIENCE

- ✓ Checkpoints persistants
- ✓ Retry automatique
- ✓ Pas d'avancement en cas d'échec
- ✓ Reprise après rétablissement
- ✓ Restart policies Docker

### PRINCIPE


Une version Delta n'est validée qu'après succès du calcul métier et de l'export.

En cas d'échec, elle reste à retraiter automatiquement.

**Une version n'est considérée comme traitée qu'après succès complet du pipeline.**


## 9. Restitution Power BI : indicateurs métier

Restituer les résultats métier produits automatiquement par le pipeline.



**Power BI restitue les données préparées par le pipeline ; une actualisation affiche les derniers résultats.**

# 10. Tableau de bord Power BI



# 11. Démonstration live : 1 événement → pipeline automatique

Prouver l'automatisation de bout en bout à partir d'une seule nouvelle activité.



Debezium → Redpanda → Consumer Python → Slack

**AUCUNE INTERVENTION MANUELLE APRÈS L'INSERT**

Une seule activité déclenche automatiquement Slack, le traitement analytique, le recalcul métier et la préparation des données Power BI.

# 12. Bilan, limites et évolutions

Un POC automatisé, observable et résilient qui valide la faisabilité technique.

## CE QUI EST VALIDÉ

- ✓ Architecture automatisée de bout en bout
  - ✓ CDC et streaming continus
  - ✓ Notifications Slack automatiques
- ✓ Calcul métier et export CSV automatiques
  - ✓ Checkpoints et reprise sur erreur
  - ✓ Restitution Power BI

## LIMITES DU POC

- Données Strava simulées
- Environnement Docker local
- Règles métier paramétrées dans le code
- Actualisation Power BI Desktop nécessaire
- POC non dimensionné pour la production

## ÉVOLUTIONS

- Connexion directe à Strava
- Paramètres métier externalisés
- Monitoring et alerting renforcés
- Orchestrateur dédié en production
  - Power BI Service
  - Déploiement cloud

**Une nouvelle activité suffit à déclencher automatiquement le traitement jusqu'aux données destinées à Power BI.**